



MUESTREO ELEMENTAL

Material de Lectura

Este material de lectura tiene la finalidad desarrollar la clase de Muestras Aleatorias y Distribuciones de Muestreo, contiene información básica y desarrollo de ejemplos particulares por cada distribución de probabilidad. La misma debe ser complementada con los textos disponibles en el programa de estudios de la asignatura

Facultad Politécnica
Facultad Politécnica U.N.A.

Índice

1. Teoría Elemental de Muestreo	1
1.1. Introducción a la teoría elemental de muestreo	1
2. Clasificación de los métodos de muestreo	3
2.1. Muestreos no probabilísticos	3
2.2. Muestreos probabilísticos	3
2.2.1. Muestreo aleatorio simple	3
2.2.2. Muestreo sistemático	4
2.2.3. Muestreo estratificado	4
2.2.4. Muestreo por conglomerados	4
2.2.5. Tamaño de muestra	4
3. Muestras aleatorias y distribuciones de muestreo.	7
3.1. Muestras aleatorias.	7
4. Distribuciones de muestreo de estadísticas.	7
4.1. Parámetro.	8
4.2. Estadística.	8
4.3. Distribución de muestreo.	9
4.4. Distribución de muestreo de medias $\bar{X}$	9
4.5. Distribución de muestreo de varianza S^2	12
4.6. Distribución t de Student	13
4.7. Distribución de diferencias entre dos medias muestrales.	14
4.8. Distribución F	15
4.8.1. Inferencias con respecto a las varianzas de dos distribuciones normales independientes.	16
4.9. Distribución Muestral de Proporciones.	17
5. Estimación	18
5.1. Propiedades que deben cumplir los estimadores.	18
5.1.1. Estimadores insesgados.	19
5.1.2. Estimadores consistentes	19
5.1.3. Estimador eficiente.	20
5.1.4. Estadísticas suficientes.	21
5.1.5. Error cuadrático.	22

6. Métodos de la estimación Puntual.	23
6.0.1. Estimación por método de máxima verosimilitud.	24
6.0.2. Estimación por el método de los momentos.	26
6.0.3. Estimación por intervalo.	28
6.0.4. Interpretación de un intervalo de confianza	28
6.0.5. Pasos para construir un intervalo de confianza	29
6.0.6. Intervalos de confianza para μ media cuando se muestrea una distribución normal con varianza conocida.	33
6.0.7. Intervalos de confianza para μ media cuando se muestrea una distribución normal con varianza desconocida.	33
6.0.8. Intervalos de confianza para la diferencia de medias cuando se muestrean dos distribuciones normales independientes. . .	34
6.0.9. Intervalos de confianza para σ^2 varianza cuando se muestrea una distribución normal con media desconocida.	34
6.0.10. Intervalos de confianza para el cociente de dos varianzas cuando se muestrean dos distribuciones normales indepen- dientes.	35
6.0.11. Intervalos de confianza para el parámetro de proporción p cuando se muestrea con distribución binomial.	36

1. Teoría Elemental de Muestreo

1.1. Introducción a la teoría elemental de muestreo

Para la estadística inferencial es muy importante el estudio del comportamiento de las variables, para ello es necesario poder encontrar estadísticos que puedan ser utilizados como parámetros de estimación. Según Canavos (1995), si se emplea una estadística T para estimar un parámetro desconocido θ , entonces T recibe el nombre de estimador de θ y el valor específico de t como un resultado de los datos muestrales recibe el nombre de estimación de θ . Un parámetro es una constante pero un estadístico es una variable aleatoria.

Para el estudio de una población se necesita conocer cierta información sobre ella, y si esta es muy extensa, dificulta estudiarlo en su totalidad, de allí la importancia de tener técnicas que ayuden a medir esta población de interés. Para una inferencia convincente y eficiente se utiliza el muestreo.

Por qué muestrear?

Porque a través de él podemos hacer análisis de situaciones de una empresa o de algún campo de la sociedad. Y porque no se estudia la población completa? se preguntarían algunos, pero en ocasiones no es factible, veamos algunas razones por las cuales conviene muestrear:

- **La naturaleza destructiva de algunas pruebas.**

Por ejemplo se quiere conocer la resistencia de los tornillos que se fabrica en una planta, para conocerla es necesario destruir el producto, lógicamente no podemos probar toda la población porque nos quedaríamos sin productos.

- **La imposibilidad física de chequear todos los elementos de la población.**

Por ejemplo se quiere conocer el efecto de un nuevo insecticida en las moscas, como se puede comprender no es posible contactar a todas las moscas para realizar el estudio.

- **El costo de estudiar a toda la población es muy alto.**

Por ejemplo se quiere conocer la opinión de la población sobre cierto personaje de la política, si en el país hay 100 millones de habitantes, se tendría que contratar mucho personal y equipo para realizar el estudio.

- **El tiempo para contactar a toda la población es inviable.**

En ocasiones se necesita información rápida para tomar una decisión importante, tal vez estudiar a toda la población nos lleve más tiempo del que disponemos.

Por las razones anteriores, en muchos casos es conveniente el uso de muestras, pero para que podamos extraer conclusiones, es importante que elijamos bien las muestras para nuestros estudios. Hay cuestiones que debemos especificar a la hora de elegir una muestra:

- El tipo de muestreo que se va a utilizar.
- El tamaño de la muestra.
- El nivel de confianza de las conclusiones que vamos a presentar.

2. Clasificación de los métodos de muestreo

Los métodos de muestreo pueden dividirse en dos grandes grupos: métodos de muestreo probabilísticos y métodos de muestreo no probabilísticos.

2.1. Muestreos no probabilísticos

No sirven para realizar generalizaciones, pues no se tiene certeza de que la muestra extraída sea representativa, ya que no todos los sujetos de la población tienen la misma probabilidad de ser elegidos. En general se seleccionan a los sujetos siguiendo determinados criterios procurando que la muestra sea representativa.

- **Muestreo intencional u opinativo:** en el que la persona que selecciona la muestra es quien procura que sea representativa, dependiendo de su intención u opinión, siendo por tanto la representatividad subjetiva.
- **Muestreo sin norma:** se toma la muestra sin norma alguna, la muestra podría ser representativa si la población es homogénea y no se producen sesgos de selección.

2.2. Muestreos probabilísticos

Los muestreos probabilísticos son aquellos en los que Cuando todos los individuos tienen la misma probabilidad de ser elegidos para formar parte de una muestra, se llama muestreo probabilístico, Dentro de los métodos de muestreo probabilísticos encontramos los siguientes tipos:

1. Muestreo aleatorio simple
2. Muestreo sistemático
3. Muestreo estratificado
4. Muestreo por conglomerados

2.2.1. Muestreo aleatorio simple

La ventaja de esta técnica de muestreo es que es fácil de comprender y relativamente sencillo llevarlo a cabo. Aunque también tiene sus desventajas como la de tener que conocer antes la lista de toda la población y cuando la muestra es pequeña no representa a la población adecuadamente.

2.2.2. Muestreo sistemático

El punto de partida de esta técnica comienza de forma aleatoria y luego procede se toma cada k -ésimo miembro para formar parte de la muestra. Su principal ventaja es su fácil aplicación, no hace falta un listado completo de la población y asegura una cobertura de todos los tipos de unidades. Aunque también tiene la desventaja de que si la constante de muestreo está asociada al fenómeno la muestra puede presentar sesgo.

2.2.3. Muestreo estratificado

Cuando para tomar las muestras se divide la población en grupos homogéneos y se selecciona una muestra de cada uno de ellos para dar representatividad a los distintos factores de interés, llamamos a esa técnica muestreo estratificado. Para seleccionar cada elemento representante de cada estrato se utiliza el método del muestreo aleatorio. Tiene la ventaja de que representa adecuadamente a la población en función de ciertas variables seleccionadas, y obtiene estimaciones más precisas. La desventaja es que hay que como se distribuye la población concorde a la variable de estudio para la estratificación.

2.2.4. Muestreo por conglomerados

Cuando la población es muy grande y dispersa y no se tiene un listado de toda la población sólo de las unidades de muestreo, este método es que es muy eficiente. Su desventaja radica en que una muestra de conglomerados, usualmente produce un mayor error muestral (por lo tanto, da menor precisión de las estimaciones acerca de la población que una muestra aleatoria simple del mismo tamaño).

El muestreo por conglomerados consiste en dividir la población en sectores o conglomerados, seleccionar una muestra aleatoria de esos sectores, y finalmente obtener una muestra aleatoria de cada uno de los sectores seleccionados. Muchas veces se le emplea para reducir el costo de realizar un muestreo de una población dispersa en una gran área geográfica.

Conglomerados: Son unidades amplias y heterogéneas que representan a la población.

2.2.5. Tamaño de muestra

Todas las técnicas mencionadas necesitan un cálculo de tamaño muestral para lo cual se utiliza las siguientes funciones

2.2.5.1 Tamaño de la muestra para población infinita o desconocida.

para estimar la media poblacional

para estimar la proporción poblacional

$$n = \frac{Z_{\alpha}^2 \cdot \sigma^2}{e^2}$$

$$n = \frac{Z_{\alpha}^2 \cdot p \cdot q}{e^2}$$

Tamaño de la muestra para población finita o conocida.

para estimar la media poblacional

para estimar la proporción poblacional

$$n = \frac{Z_{\alpha}^2 \cdot \sigma^2}{e^2(N-1) + Z_{\alpha}^2 \cdot \sigma^2}$$

$$n = \frac{Z_{\alpha}^2 \cdot p \cdot q}{e^2(N-1) + Z_{\alpha}^2 \cdot p \cdot q}$$

Donde:

- n: tamaño muestral
- N: tamaño de la población
- Z: valor correspondiente a la distribución normal, los más usados son $Z_{\alpha=0,05} = 1,96$ y $Z_{\alpha=0,01} = 2,58$
- p: Probabilidad esperada del parámetro a evaluar, en caso de desconocer se usa ($p = 0,5$), que hace mayor el tamaño muestral α
- q: $1 - p$
- e: error que se prevé cometer, si es del 10 %, $e = 0,1$.

Para poder tener una idea más clara del calculo del tamaño muestral, veamos el siguiente ejemplo del libro Triola (2004) pagina 329, en este caso se busca n para proporciones.

Ejemplo 2.1 (Ejercicio de ejemplo sobre tamaño muestral para proporciones). *Suponga que un sociólogo quiere determinar el porcentaje actual de hogares en Estados Unidos que utilizan el correo electrónico. ¿Cuántos hogares deben encuestarse para tener una confianza del 95 % de que el porcentaje muestral es erróneo por no más de 4 puntos porcentuales?*

- Utilice el siguiente resultado de un estudio pionero: en 1997, el 16,9% de los hogares estadounidenses usaban correo electrónico (según datos de *The World Almanac and Book of Facts*).

Desarrollo

La función para proporciones es;

$$n = \frac{Z_{\alpha}^2 \cdot p \cdot q}{e^2}$$

El estudio sugiere que $\hat{p} = 0,169$, entonces $\hat{q} = 1 - \hat{p} = 0,831$, para el nivel de confianza del 95%, $\alpha = 0,05$ y $Z_{\alpha/2} = 1,96$, el margen de error $e = 0,04$, entonces

$$n = \frac{(1,96)^2 \cdot 0,169 \cdot 0,831}{(0,04)^2} = 337,194 \approx 338$$

Siguiendo con el ejemplo de Triola (2004) de la página 344 con el siguiente enunciado

Ejemplo 2.2 (Ejercicio de ejemplo sobre tamaño muestral de medias). *Puntuaciones de CI de profesores de estadística Suponga que queremos estimar la puntuación media del CI de la población de profesores de estadística. Los profesores de estadística tienen puntuaciones de CI con una media mayor que 100 y una desviación estándar menor que 15. Cuántos profesores de estadística deben seleccionarse al azar para efectuar pruebas de CI, si queremos tener una confianza del 95% de que la media muestral estará dentro de 2 puntos de CI de la media poblacional?*

Desarrollo

Para el encontrar el valor de n para este ejemplo se utiliza la función

$$n = \frac{Z_{\alpha}^2 \cdot \sigma^2}{e^2}$$

Teniendo en cuenta que el valor para $Z_{\alpha=0,05} = 1,96$, $\sigma = 15$ y $e = 2$

$$n = \frac{(Z_{\alpha}^2 = 1,96^2) \cdot (\sigma^2 = 15^2)}{e^2 = 2^2} = 216,09$$

Entonces $n = 217$

3. Muestras aleatorias y distribuciones de muestreo.

Para una inferencia estadística aceptable y confiable es necesario la selección de una buena muestra. Entonces si una población de N objetos y de éstos se selecciona una muestra de tamaño n , el proceso debe asegurar misma probabilidad para cada tamaño de muestra. (Canavos, 1995)

3.1. Muestras aleatorias.

(Walpole, 2012), expresa que una muestra aleatoria es cuando las observaciones se realizan de forma independiente y al azar.

Definición 3.1 (Muestra Aleatoria). Sean $X_1, X_2, \dots, X_n$ variables aleatorias independientes n , cada una con la misma distribución de probabilidad $f(x)$. Definimos $X_1, X_2, \dots, X_n$ como una muestra aleatoria de tamaño n de la población $f(x)$ y escribimos su distribución de probabilidad conjunta como

$$f(x_1, x_2, \dots, x_n) = f(x_1), f(x_2), \dots, f(x_n).$$

4. Distribuciones de muestreo de estadísticas.

Según (Canavos, 1995), el examinar con detalle el papel que desempeñan las estadísticas en relación a la inferencia para ello se utiliza las distribuciones de muestreo de estadísticas, uno de los conceptos más importantes.

Definición 4.1 (Distribuciones de muestreo de Estadísticas). Cualquier función de la variables aleatorias que forman una muestra aleatoria se llama **estadísticos o estadísticas**.

Según la definición de Distribuciones de muestreo de Estadísticas, una La distribución de muestreo de una estadística es la distribución de esa estadística, considerada como una variable aleatoria, cuando se deriva de una muestra aleatoria de tamaño n . Es decir depende de la distribución subyacente de la población, la estadística que se considera, el procedimiento de muestreo empleado y el tamaño de muestra utilizado.

4.1. Parámetro.

Definición 4.2 (Parámetro). *Un parámetro es una caracterización numérica de la distribución de la población de manera que describe, parcial o completamente, la función de densidad de probabilidad de la característica de interés.*

Media Muestral

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Mediana muestral

$$\tilde{x} = \begin{cases} \frac{x_{n+1}}{2} & \text{si } n \text{ es impar} \\ \frac{1}{2}(x_{n/2} + x_{n/2+1}) & \text{si } n \text{ es par} \end{cases}$$

Varianza muestral

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

4.2. Estadística.

Definición 4.3. *Una estadística es cualquier función de la variables aleatorias que se observaron en la muestra de manera que esta función no contiene cantidades desconocidas.*

Considera la muestra $X_i = X_1, X_2, \dots, X_n$ que consiste en n variables aleatorias *iid* con una función de densidad de probabilidad $f(x; \theta)$, que depende de un parámetro desconocido θ .

Suponga que se definen funciones como

$$T_1(X_i) = (X_1, X_2, \dots, X_n)/n,$$

$$T_2(X_i) = (X_1^2, X_2^2, \dots, X_n^2)/n,$$

$$T_3(X_i) = X_1 + X_2,$$

y así sucesivamente. Todas ellas son estadísticas por que se determinan de manera completa por las variables aleatorias que contiene a la muestra. De manera general, denótese una estadística por $T = \mu(X_i)$. Dado que T es una función de variables aleatorias, es en sí misma una variable aleatoria, y su valor específico $t = \mu(X_i)$ puede determinarse cuando se conozcan las realizaciones.

4.3. Distribución de muestreo.

Las poblaciones a considerar en el estudio pueden considerarse de como poblaciones finitas e infinitas.

Definición 4.4 (Distribucion Muestral). *La distribución de probabilidad de un estadístico se denomina **distribución muestral**.*

4.4. Distribución de muestreo de medias $\bar{X}$.

La distribución muestral de medias con tamaño muestral n es la distribución que resulta cuando un experimento se lleva a cabo una y otra vez siempre con una muestra de tamaño n y resultan los diversos valores de $\bar{X}$. Lo cual describe la variabilidad de los promedios muestrales alrededor de la media poblacional. (Walpole, 2012)

Teorema 4.5 (Teorema del límite central). *Si $\bar{X}$ es la media de una muestra aleatoria de tamaño n , tomada de una población con media μ y varianza finita σ^2 , entonces la forma límite de la distribución de*

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

a medida que $n \rightarrow \infty$, es la distribución normal estándar $n(z; 0, 1)$.

Se puede ver con un ejemplo que el teorema funciona perfectamente incluso en situaciones donde la distribución tienen un mal comportamiento. Una prueba con el lanzamiento de dados;




Figura 1: Ejemplo de Teorema del límite central en lanzamiento de dados

Para entender mejor el uso del teorema del límite central, veamos el siguiente ejemplo del libro Walpole (2012) pagina 234,

Ejemplo 4.6 (Ejercicio de ejemplo sobre Teorema del límite central.). *Una empresa de material eléctrico fabrica bombillas que tienen una duración que se distribuye aproximadamente en forma normal, con media de 800 horas y desviación estándar de 40 horas. Calcule la probabilidad de que una muestra aleatoria de 16 bombillas tenga una vida promedio de menos de 775 horas.*

Desarrollo

como la distribución es aproximadamente normal, podemos usar la normal estándar, usamos

$$Z = \frac{(\bar{X} = 775) - (\mu = 800)}{(\sigma = 40)/(\sqrt{n = 16})} = -2,5$$




Figura 2: Área para $P(Z < 2,5)$

entonces

$$P(\bar{X} < 775) = P(Z < -2,5) = 0,0062$$

Walpole (2012) menciona en su ejemplo de la página 237 que,

Ejemplo 4.7. Ejercicios de ejemplo sobre teorema del límite central. El viaje en un autobús especial para ir de un campus de una universidad al campus de otra en una ciudad toma, en promedio, 28 minutos, con una desviación estándar de 5 minutos. En cierta semana un autobús hizo el viaje 40 veces. ¿Cuál es la probabilidad de que el tiempo promedio del viaje sea mayor a 30 minutos? Suponga que el tiempo promedio se redondea al entero más cercano.

Desarrollo de nuevo usamos

$$Z = \frac{(\bar{X} = 30,5) - (\mu = 28)}{(\sigma = 5)/(\sqrt{n} = 40)} = 3,16$$

En este caso el área de probabilidad de interés está por encima de $\bar{X} > 30$ luego

$$P(\bar{X} > 30) = P(Z > 3,16) = 0,0008$$

La probabilidad de que el tiempo promedio de un viaje del autobús exceda 30 minutos es de 0,0008.

4.5. Distribución de muestreo de varianza S^2 .

Siempre que estemos interesados en el estudio de la variabilidad de una muestra, tenemos que recurrir a la distribución muestral de S^2 , para conocer la varianza de la población σ^2 .

Definición 4.8. Si S^2 es la varianza de una muestra aleatoria de tamaño n que se toma de una población normal que tiene la varianza σ^2 , entonces el estadístico

$$\chi^2 = \frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma^2}$$

tiene una distribución chi cuadrada con $v = n - 1$ grados de libertad.

Los valores de la variable aleatoria χ^2 se calculan mediante la función

$$\chi^2 = \frac{(n-1)S^2}{\sigma^2}$$

Si las variables aleatorias $X_1, X_2, \dots, X_n$ son muestras de una distribución normal con media μ y varianza desconocida $\sigma^2 > 0$.




Figura 3: Distribución χ^2

4.6. Distribución t de Student

Si la muestra es pequeña S es análogo de la muestra para σ . Si $n < 30$ es útil tratar con la distribución de T . π

Definición 4.9. Sea Z una variable aleatoria normal estándar y V una variable aleatoria chi cuadrada con v grados de libertad. Si Z y V son independientes, entonces la distribución de la variable aleatoria T , donde

$$\frac{Z}{\sqrt{V/v}}$$

es dada por la función de densidad

$$\frac{\Gamma[(v+1)/2]}{\Gamma(v/2)\sqrt{\pi v}} \left(1 + \frac{t^2}{v}\right)^{-(v+1)/2}$$

ésta función es conocida como la distribución t con v grados de libertad.

A partir de este teorema se desprende el corolario siguiente

Corolario 4.10. Sean $X_1, X_2, \dots, X_n$ variables aleatorias independientes normales con media μ y desviación estándar σ . Sea

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

y

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Entonces la variable aleatoria $\frac{\bar{X} - \mu}{S/\sqrt{n}}$ tiene una distribución t con $v = n-1$ grados de libertad.




Figura 4: Distribución t – student

4.7. Distribución de diferencias entre dos medias muestrales.

Una aplicación más amplia de la distribución de medias es para el caso donde el interés del investigador abarca no sólo una población sino dos, para poder comparar ambas poblaciones, se toman muestras que están distribuidas más o menos normalmente y de forma independientes. Entonces el teorema del límite central se puede ampliar fácilmente al caso de dos muestras y dos poblaciones.

Teorema 4.11 (Distribución de diferencias de medias). n_1 y n_2 muestras independientes de dos poblaciones, con medias μ_1 y μ_2 y varianzas σ_1^2 y σ_2^2 , entonces la distribución muestral de las diferencias de las medias $\bar{X}_1 - \bar{X}_2$, tiene una distribución aproximadamente normal, con medias y varianzas dadas por

$$\begin{aligned}\mu_{\bar{X}_1 - \bar{X}_2} &= \mu_1 - \mu_2 \\ \sigma_{\bar{X}_1 - \bar{X}_2}^2 &= \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\end{aligned}$$

De aquí;

$$Z = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

4.8. Distribución F .

Teorema 4.12. Sean U y V dos variables aleatorias independientes que tienen distribuciones chi cuadrada con v_1 y v_2 grados de libertad, respectivamente. Entonces, la distribución de la variable aleatoria $F = \frac{U/v_1}{V/v_2}$ es dada por la función de densidad

$$h(f) = \frac{[\Gamma(v_1 + v_2)/2](v_1/v_2)^{v_1/2}}{\Gamma(v_1/2)\Gamma(v_2/2)} \frac{f^{(v_1/2)-1}}{(1 + v_1 f/v_2)^{(v_1+v_2)/2}}$$

ésta es conocida como la distribución F con v_1 y v_2 grados de libertad.

Consideremos dos variables aleatorias independientes Y y W tales que Y tiene una distribución χ^2 con m grados de libertad y W una distribución χ^2 con n grados de libertad, donde m y n son enteros positivos. Se define una nueva variable aleatoria como sigue:

$$X = \frac{\frac{Y}{m}}{\frac{W}{n}} = \frac{nY}{mW}$$

entonces a la variable aleatoria X se le denomina **distribución F de Snedecor** con m y n grados de libertad.

Definición 4.13. Una variable aleatoria X tiene distribución F de Snedecor si su función de densidad de probabilidad está dada por

$$f(x) = \begin{cases} \frac{\Gamma\left(\frac{m+n}{2}\right)m^{\frac{m}{2}}n^{\frac{n}{2}}}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)} \cdot \frac{x^{\frac{m}{2}-1}}{(mx+n)^{\frac{m+n}{2}}} & \text{si } x > 0 \\ 0 & \text{si } x \leq 0 \end{cases}$$




Figura 5: Distribución F

Gráfica de $f(x)$ cuando los parámetros m y n toman diferentes pares de valores.

Las características de la distribución F

- Hay una **familia** de distribuciones F . Cada miembro de esta familia está determinado por los grados de libertad del numerador (varianza mayor) y por los del denominador (varianza menor).
- La distribución F es una distribución continua y no puede tomar valores negativos.
- La curva que representa la distribución F está sesgada hacia la derecha.
- Su rango de valores va desde 0 hasta infinito, cuanto más se incrementa F , la curva se aproxima al eje X , pero nunca lo toca.

4.8.1. Inferencias con respecto a las varianzas de dos distribuciones normales independientes.

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución normal con media μ_X y varianza σ_X^2 , sea además $Y_1, Y_2, \dots, Y_m$ otra muestra aleatoria de una distribución normal con media μ_Y y varianza σ_Y^2 . Si se supone independencia entre las

variables aleatorias X e Y , las estadísticas $u_X = \frac{(n-1)S_X^2}{\sigma_X^2}$ y $u_Y = \frac{(m-1)S_Y^2}{\sigma_Y^2}$ son distribuciones ji-cuadradas con $n-1$ y $m-1$ grados de libertad. Entonces

$$F = \frac{\frac{u_X}{n-1}}{\frac{u_Y}{m-1}} = \frac{\frac{S_X^2}{\sigma_X^2}}{\frac{S_Y^2}{\sigma_Y^2}}$$

tiene una distribución F con $n-1$ y $m-1$ grados de libertad.

Si las dos varianzas poblacionales son iguales la fórmula se reduce a:

$$F = \frac{S_X^2}{S_Y^2}$$

4.9. Distribución Muestral de Proporciones.

Sea una población finita de tamaño N , en la que la probabilidad de ocurrencia de un suceso en el que se está interesado es P y la probabilidad de ocurrencia del suceso contrario a aquel en el que se está interesado es $Q = 1 - P$ (población Bernoulli). Si de esta población se extraen todas las posibles muestras de tamaño n , con $n < N$, y se averigua para cada una de las muestras la proporción correspondiente al atributo o categoría en el que se está interesado con relación al total de elementos n de la muestra se obtendrá una distribución muestral de proporciones.

Se define una proporción de muestra como $\hat{p} = \frac{X}{n}$, donde X es el número de unidades de la muestra que posee el rasgo en el que se está interesado y n es el tamaño de muestra. Por su forma de definición X es la suma de las variables aleatorias Bernoulli de la muestra que poseen el rasgo de interés y por lo tanto X tiene distribución Binomial con parámetro P .

Si se obtiene una muestra de tamaño n al azar, con reemplazamiento (reposición), la distribución por muestreo de P , obedece a la ley de probabilidad binomial. La media y la varianza están dadas por:

$$E(\hat{p}) = \mu_{\hat{p}} = E\left(\frac{X}{n}\right) = \frac{E(X)}{n} = \frac{nP}{n} = P$$

$$\sigma_{\hat{p}}^2 = Var\left(\frac{X}{n}\right) = \frac{Var(X)}{n^2} = \frac{nP(1-P)}{n^2} = \frac{P(1-P)}{n}$$

para muestras de tamaño $n < 30$.

Cuando el muestreo se realiza sin sustitución, obedece a la ley de probabilidades hipergeométrica y como la población es finita, la media y la varianza están dadas por

$$E(\hat{p}) = \mu_{\hat{p}} = E\left(\frac{X}{n}\right) = \frac{E(X)}{n} = \frac{1}{n} \cdot \frac{nk}{N} = \frac{k}{N} = P$$
$$\sigma_{\hat{p}}^2 = Var\left(\frac{X}{n}\right) = \frac{Var(X)}{n^2} = \frac{nk(N-k)(N-n)}{n^2 N^2 (N-1)} = \frac{1}{n} \cdot \frac{k}{N} \cdot \left(1 - \frac{k}{N}\right) \cdot \frac{N-n}{N-1} = \frac{P(1-P)}{n} \cdot \frac{N-n}{N-1}$$

Cuando el muestreo es efectuado ya sea con o sin reemplazamiento, si el tamaño de las muestras es $n \geq 30$, la distribución muestral de las proporciones en las muestras se aproxima a la normal por aplicación del teorema central del límite. A continuación se enuncia el teorema central del límite para este caso.

5. Estimación

En un problema de estadística se han de analizar datos que han sido generados de acuerdo con una distribución de probabilidad desconocida y en el que se debe realizar algún tipo de inferencia acerca de tal distribución. En estos tipos de problemas existen dos o más distribuciones de probabilidad que podrían haber generado algunos datos experimentales.

En los problemas reales mayormente, existe un número infinito de distribuciones posibles distintas que podrían haber generado los datos. Analizando los datos, se intenta conocer la distribución desconocida para realizar inferencias acerca de ciertas propiedades de la distribución y determinar la verosimilitud relativa que cada distribución posible tiene de ser la correcta. Los problemas que se tratan en la inferencia estadística se dividen generalmente en dos clases: los problemas de estimación y los de prueba de hipótesis.

El procedimiento mediante el cual; a partir del conocimiento de las características de la muestra que llamaremos estimadores; inferimos las características de la población se llama estimación, que a su vez se divide en estimación puntual y estimación por intervalos.

5.1. Propiedades que deben cumplir los estimadores.

Definición 5.1. Sea X una v.a. con una distribución de probabilidad que depende de un parámetro desconocido θ perteneciente a un espacio paramétrico Ω . Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de X . Además sean $x_1, x_2, \dots, x_n$ los valores

muestrales correspondientes. Si $g(X_1, X_2, \dots, X_n)$ es una función de la muestra que va a ser usada para estimarle a θ , nos referimos a g como un estimador de θ .

El valor que toma g , es decir $g(x_1, x_2, \dots, x_n)$ será mencionado como una estimación de θ y habitualmente es escrito como: $\hat{\theta} = g(x_1, x_2, \dots, x_n)$

5.1.1. Estimadores insesgados.

Se dice que un estimador para un parámetro poblacional es insesgado si su valor esperado es igual al verdadero valor del parámetro poblacional. Esto es; si $\hat{\theta}$ es el estimador y θ es el parámetro entonces:

$$E(\hat{\theta}) = \theta$$

Ejemplo 5.2. Sea $\hat{p} = \frac{X}{n}$ un estimación del parámetro P ; donde X es una v.a. binomial con parámetros P y n . Probar que $\hat{p}$ es un estimador insesgado de P .

Recordemos que si $X \sim \text{bin}(P, n)$ tendremos que $E(X) = nP$. Entonces

$$E(\hat{p}) = E\left(\frac{X}{n}\right) = \frac{1}{n}E(X) = \frac{1}{n}nP = P$$

por lo que $\hat{p}$ es un estimador insesgado de P .

5.1.2. Estimadores consistentes

Un estadístico es un estimador consistente de un parámetro poblacional, si a medida que aumenta el tamaño de la muestra se tiene casi la certeza de que el valor del estadístico se aproxima bastante al valor del parámetro de la población. Entonces, $\hat{\theta}$ es un estimador consistente del parámetro θ si, para cualquier número $\varepsilon > 0$, la probabilidad de que la diferencia entre el estimador $\hat{\theta}$ y el parámetro θ sea menor que ε tienda a la unidad cuando el tamaño de la población (n) tiende al infinito. Es decir:

$$P(|\hat{\theta} - \theta| < \varepsilon) \rightarrow 1 \quad \text{cuando} \quad n \rightarrow \infty$$

Ejercicio 5.1. Sea $\hat{\theta}$ una estimación del parámetro θ basada en una muestra de tamaño n ; si $\lim_{n \rightarrow \infty} E(\hat{\theta}) = \theta$, y si $\lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}) = 0$; entonces $\hat{\theta}$ es una estimación convergente de θ .

Ejemplo 5.3. La media muestral es un estimador convergente o consistente del parámetro μ , ya que

$$\lim_{n \rightarrow \infty} E(\bar{X}) = \lim_{n \rightarrow \infty} \mu = \mu \quad \text{y} \quad \lim_{n \rightarrow \infty} \text{Var}(\bar{X}) = \lim_{n \rightarrow \infty} \frac{\sigma^2}{n} = 0$$

5.1.3. Estimador eficiente.

La eficiencia se refiere al tamaño de la varianza del estadístico. Si comparamos dos estadísticos; $\hat{\theta}_1$ y $\hat{\theta}_2$ ambos insesgados con varianzas $Var(\hat{\theta}_1)$ y $Var(\hat{\theta}_2)$ respectivamente; y tratamos de decidir cual de ellos es un estimador más eficiente, escogeríamos al que tuviese la menor varianza, es decir se preferirá a $\hat{\theta}_1$ si $Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$. El estadístico eficiente recibe el nombre estadístico ó estimador insesgado de varianza mínima.

Ejemplo 5.4. Sea una población con media μ y varianza σ^2 . La distribución muestral de medias tiene media dada por $E(\bar{X}) = \mu$ y varianza $Var(\bar{X}) = \frac{\sigma^2}{n}$ y la distribución muestral de medianas tiene también media $E(X_{mediana}) = \mu$, pero varianza $Var(X_{mediana}) = \frac{\pi\sigma^2}{2n}$. Vemos que $\bar{X}$ y $X_{mediana}$ son estimadores insesgados del parámetro μ y además $Var(\bar{X}) < Var(X_{mediana})$, por lo que $\bar{X}$ es un estimador eficiente de μ .

También se pueden comparar dos estimadores en base a su eficiencia relativa. Sean $\hat{\theta}_1$ y $\hat{\theta}_2$ dos estimadores diferentes del parámetro θ . La eficiencia relativa de $\hat{\theta}_2$, comparada con $\hat{\theta}_1$, se define por la razón:

$$R = \frac{E(\hat{\theta}_1 - \theta)^2}{E(\hat{\theta}_2 - \theta)^2} \quad (1)$$

- Si $R > 1$, $\hat{\theta}_2$ será relativamente más eficiente que $\hat{\theta}_1$.
- Si $R < 1$, $\hat{\theta}_1$ será relativamente más eficiente que $\hat{\theta}_2$.

En la ecuación anterior $E(\hat{\theta}_i - \theta)^2$, para $i = 1, 2$ se llama error cuadrático medio y pueden escribirse como

$$E(\hat{\theta}_i - \theta)^2 = Var(\hat{\theta}_i) + [\theta - E(\hat{\theta}_i)]^2$$

donde $\theta - E(\hat{\theta}_i)$ se llama **sesgo del estimador** y puede ser positivo, negativo ó cero. Si es cero el estimador será insesgado.

Si $\hat{\theta}_1$ y $\hat{\theta}_2$ son insesgados, la eficiencia relativa no es más que el cociente de sus varianzas.

$$R = \frac{Var(\hat{\theta}_1)}{Var(\hat{\theta}_2)} \quad (2)$$

5.1.4. Estadísticas suficientes.

Definición 5.5. Consideremos una muestra aleatoria $X_1, X_2, \dots, X_n$ tomada de una población con distribución $f(x|\theta)$ y sean $Y_1, Y_2, \dots, Y_n$ estadísticos muestrales. Un estadístico $Y_1 = Y_1(X_1, X_2, \dots, X_n)$ se denomina suficiente si la distribución condicional $f(y_2, y_3, \dots, y_n|y_1, \theta) = f(y_2, y_3, \dots, y_n|y_1)$.

La definición anterior nos dice que un estimador $\hat{\theta}$ es suficiente si utiliza una cantidad de la información contenida de la muestra y además ningún otro estimador podría extraer información adicional de la muestra sobre el parámetro de la población θ que se está estimando que no sea ya suministrada por $\hat{\theta}$.

Criterio de Fisher-Neyman Un estadístico $Y_1 = Y_1(X_1, X_2, \dots, X_n)$ es suficiente, si y sólo si:

$$f(x_1, x_2, \dots, x_n|\theta) = \prod_{i=1}^n f(x_i|\theta) = f(y_1|\theta)h(x_1, x_2, \dots, x_n)$$

donde h no contiene a θ .

Ejemplo 5.6. Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria tomada de una distribución Bernoulli con parámetro $0 < p < 1$. Verificar que el estadístico $Y_1 = X_1 + X_2 + \dots + X_n$ es suficiente.

Como la población tiene distribución Bernoulli con parámetro $0 < p < 1$, la distribución conjunta de $X_1, X_2, \dots, X_n$ está dada por

$$f(x_1, x_2, \dots, x_n|p) = \prod_{i=1}^n f(x_i|p) = \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{\sum_{i=1}^n (1-x_i)}$$

Ejemplo 5.7. Como el estadístico Y_1 está dada por la relación $Y_1 = X_1 + X_2 + \dots + X_n$ entonces tiene distribución binomial con parámetro p esto es

$$f(y_1|p) = \frac{n!}{y_1!(n-y_1)!} p^{y_1} (1-p)^{n-y_1}$$

donde $y_1 = \sum_{i=1}^n x_i$.

De las dos relaciones anteriores tendremos que

$$f(x_1, x_2, \dots, x_n|p) = f(y_1|p) \frac{y_1!(n-y_1)!}{n!}$$

con lo cual según el criterio de Fisher-Neyman $Y_1 = \sum_{i=1}^n X_i$ es un estimador suficiente.

5.1.4.1 Estimadores insesgados de varianza mínima.

Una extensión más de lo que es el estimador eficiente, como ya se nombro el estimador insesgado de mínima varianza busca que la varianza de un estimador sea lo más pequeño posible, se busca entre los estimadores insesgados si es que éste existe, tenga una varianza mínima para todos los valores posibles del parámetro. Este estimador recibe el nombre de estimador insesgado de varianza mínima uniforme del parámetro.

Definición 5.8. Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución cuya función de densidad de probabilidad es $f(x; \theta)$. Sea la estadística $T = u(X_1, X_2, \dots, X_n)$ un estimador de θ tal que $E(T) = \theta$ es menor que la varianza de cualquier otro estimador insesgado de θ para todos los posibles valores de θ . Se dice entonces que T es un estimador insesgado de varianza mínima de θ .

La forma que facilita el cálculo de este estimador es la cota inferior de Cramer-Rao,

Teorema 5.9. Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución con función de densidad de probabilidad es $f(x; \theta)$. Si T es un estimador insesgado de θ , entonces la varianza de T debe satisfacer la desigualdad

$$V(T) \geq \frac{1}{nE\left[\left(\frac{\partial \ln f(X; \theta)}{\partial \theta}\right)^2\right]}$$

5.1.5. Error cuadrático.

Teniendo en cuenta que una medida de la calidad de un estimador insesgado es su varianza. La varianza de $\bar{X}$ es

$$\sigma_{\bar{X}}^2 = \frac{\sigma^2}{n}$$

De esta forma, la desviación estándar de $\bar{X}$ o error estándar de $\bar{X}$ es $\frac{\sigma}{\sqrt{n}}$. En términos simples, el error estándar de un estimador es su desviación estándar. Para el caso de $\bar{X}$ el límite de confianza que se calcula

$$\bar{X} \pm Z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

El ancho del intervalo de confianza de μ depende de la calidad del estimador puntual a través de su error estándar.

En el caso que se desconoce σ y la muestra proviene de una distribución normal, se reemplaza a σ y se incluye el error estándar estimado $S/\sqrt{n}$ entonces los límites de confianza para μ son;

$$\bar{x} \pm t_{\alpha/2} \frac{S}{\sqrt{n}}$$

De nuevo, el intervalo de confianza no es mejor (en términos de anchura) que la calidad de la estimación puntual, en este caso a través de su error estándar estimado. A medida que avanzamos a intervalos de confianza más complejos, prevalece el concepto de que el ancho de los intervalos de confianza se acorta cuando mejora la calidad de la estimación puntual correspondiente, aunque no siempre es tan sencillo como aquí se ilustra. Se puede argumentar que un intervalo de confianza es tan sólo una ampliación de la estimación puntual para tomar en cuenta la exactitud de dicha estimación.

6. Métodos de la estimación Puntual.

El objetivo de la estimación puntual es obtener valores puntuales aproximados de los parámetros poblacionales. Consiste en considerar que el parámetro poblacional es aproximadamente igual al estimador o valor puntual obtenido a partir de la información de la muestra.

Ejemplo 6.1. *Los siguientes datos corresponden a una muestra aleatoria de las estaturas de jugadores de baloncesto de una liga local. Vamos a realizar una estimación puntual de la estatura promedio de los jugadores de baloncesto de esta liga.*

1,95 2,15 1,83 2,04 2,02 1,80 1,85 2,05 1,99 1,95

Se calcula la media aritmética de la muestra de los 10 basquetbolistas: $\bar{X} = \frac{1}{10} \sum_{i=1}^{10} x_i = 1,96$. Como es una estimación puntual, se establece que la estatura promedio de los jugadores de baloncesto de esta liga es aproximadamente igual a 1,96 metros. Esto es $\mu = 1,96$.

Supongamos ahora que extraemos una muestra aleatoria de una población con cierta distribución de probabilidad y queremos estimar un cierto parámetro de esta población a través de la muestra tomada. Existen dos métodos de estimación puntual de un parámetro poblacional:

- Método de máxima verosimilitud
- Método de los momentos

6.0.1. Estimación por método de máxima verosimilitud.

Consideremos una distribución de probabilidad concreta sobre la recta real que puede ser representada por una función de probabilidad o una función de densidad de probabilidad f . Recordemos que n variables aleatorias $X_1, X_2, \dots, X_n$ constituyen una muestra aleatoria de esta distribución si son independientes y están idénticamente distribuidas, es decir que cada X_i , $\forall i = 1, 2, \dots, n$ tiene función de probabilidad o función de densidad de probabilidad dada por f . En otras palabras, las variables aleatorias $X_1, X_2, \dots, X_n$ constituyen una muestra aleatoria de la distribución representada por f si su función de probabilidad o función de densidad de probabilidad conjunta g para los puntos reales $x_1, x_2, \dots, x_n$ se especifica como sigue:

$$g(x_1, x_2, \dots, x_n) = f(x_1) \cdot f(x_2) \cdots f(x_n)$$

Considérese un problema de inferencia estadística en el que se van a seleccionar observaciones de una distribución cuya función de probabilidad o de densidad de probabilidad es $f(x|\theta)$, donde θ es un parámetro desconocido. Se supone que el valor desconocido del parámetro θ debe pertenecer a un espacio paramétrico Ω . El problema de estimación consiste en intentar determinar donde es probable que se encuentre el verdadero valor de θ en Ω , partiendo de las observaciones de $f(x|\theta)$.

Si las variables aleatorias $X_1, X_2, \dots, X_n$ constituyen una muestra aleatoria de una distribución cuya función de probabilidad o de densidad de probabilidad es $f(x|\theta)$, entonces la función de probabilidad o de densidad de probabilidad conjunta de las variables aleatorias $X_1, X_2, \dots, X_n$, está dada por:

$$L(x_1, x_2, \dots, x_n|\theta) = f(x_1|\theta) \cdot f(x_2|\theta) \cdots f(x_n|\theta)$$

Cuando la función de probabilidad o de densidad de probabilidad conjunta $L(x_1, x_2, \dots, x_n|\theta)$ de las observaciones de una muestra aleatoria se considera como una función de θ para los valores $x_1, x_2, \dots, x_n$ se llama **función de verosimilitud**.

Ejemplo 6.2. Supongamos que las variables aleatorias $X_1, X_2, \dots, X_n$ constituyen una muestra aleatoria de una distribución de Bernoulli con parámetro p desconocido ($0 \leq p \leq 1$). Encontrar la función de verosimilitud.

Desarrollo

Como cada X_i ; $\forall i = 1, 2, \dots, n$; tiene distribución de Bernoulli entonces

$$f(x) = \begin{cases} p^{x_i}(1-p)^{1-x_i} & \text{si } x = 0, 1 \\ 0 & \text{en otro caso} \end{cases}$$

por lo que la función de verosimilitud es

$$L(x_1, x_2, \dots, x_n | p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{\sum_{i=1}^n (1-x_i)}$$

Pasos para obtener el estimador de verosimilitud

- Tomar una muestra aleatoria de tamaño n de la población cuyo parámetro θ se desea estimar.
- Establecer la forma de la función de probabilidad o densidad de probabilidad de la población.
- Obtener la función de verosimilitud a partir de la muestra.
- Por ultimo el estimador de verosimilitud será el valor de θ que maximiza al logaritmo de la función de verosimilitud.

Ejemplo 6.3. Suponiendo que el tiempo para fallar T , de una componente tiene una distribución exponencial con parámetro β desconocido. Si se extrae una muestra aleatoria de tamaño n de esta población, hallar el estimador de verosimilitud de β .

Desarrollo

Como cada T_i , $\forall i = 1, 2, \dots, n$ tiene distribución exponencial con parámetro β por ser una muestra aleatoria proveniente de una población exponencial con dicho parámetro entonces

$$f(t_i) = \begin{cases} \beta e^{-\beta t_i} & \text{si } t_i > 0 \\ 0 & \text{en otro caso} \end{cases}$$

por lo que la función de verosimilitud es

$$L(x_1, x_2, \dots, x_n | p) = \prod_{i=1}^n \beta e^{-\beta t_i} = \beta^n e^{-\beta \sum_{i=1}^n t_i}$$

entonces el logaritmo de esta función esta dada por la siguiente relación

$$\log L(x_1, x_2, \dots, x_n | p) = \log \beta^n e^{-\beta \sum_{i=1}^n t_i}$$

Aplicando propiedades de logaritmo tenemos

$$\log L(x_1, x_2, \dots, x_n | p) = n \cdot \log \beta - \beta \sum_{i=1}^n t_i$$

Derivando parcialmente con respecto a β la expresión anterior e igualando a cero se obtiene la siguiente relación

$$\frac{\partial}{\partial \beta} (\log L(x_1, x_2, \dots, x_n | p)) = n \frac{1}{\beta} - \sum_{i=1}^n t_i = 0$$

con lo cual

$$\hat{\beta} = \frac{n}{\sum_{i=1}^n t_i} = \frac{1}{\bar{t}}$$

Entonces el estimador verosimil de β es $\hat{\beta} = \frac{1}{\bar{t}}$.

6.0.2. Estimación por el método de los momentos.

Recordemos que la definición del r -ésimo momento alrededor del origen de una v.a. X está dada por $E(X^r)$.

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución con función de probabilidad o de densidad de probabilidad $f(X|\theta)$. El r -ésimo momento muestral alrededor del origen se define por

$$m_r = \frac{1}{n} \sum_{i=1}^n X_i^r$$

El método de los momentos proporciona una alternativa razonable cuando no se puede determinar los estimadores de máxima verosimilitud. Este método consiste en igualar los momentos apropiados de la distribución de la población, con los

correspondientes momentos muestrales para estimar un parámetro desconocido de la distribución.

Sea $f(x|\theta_1, \theta_2, \dots, \theta_k)$ una función de probabilidad o de densidad con k parámetros y designemos por $\mu_1, \mu_2, \dots, \mu_k$, los primeros k momentos alrededor del origen, es decir

$$\mu_t = \begin{cases} \sum_x x^t f(x|\theta_1, \theta_2, \dots, \theta_k) & \text{si } X \text{ es discreta} \\ \int_{-\infty}^{\infty} x^t f(x|\theta_1, \theta_2, \dots, \theta_k) dx & \text{si } X \text{ es continua} \end{cases}$$

para $t = 1, 2, \dots, k$.

En general μ_t será función de los k parámetros. Sea ahora $X_1, X_2, \dots, X_n$ una muestra aleatoria de tamaño n de $f(x|\theta_1, \theta_2, \dots, \theta_k)$. A partir de esta muestra formamos los k primeros momentos muestrales $m_1, m_2, \dots, m_n$. Sean $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ las soluciones que resultan de las k ecuaciones $m_t = \mu_t$, para $t = 1, 2, \dots, k$. Las soluciones $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ constituyen los estimadores por el método de los momentos.

Ejemplo 6.4. Sea una población normal con parámetros μ y σ^2 , ambas desconocidas. Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de tamaño n de esta distribución. Obtener por el método de los momentos las estimaciones de μ y de σ^2 .

Desarrollo

Como la distribución es normal entonces $E(X) = \mu$ y $Var(X) = \sigma^2$. Además recordemos que $Var(X) = E(X^2) - [E(X)]^2$, entonces $E(X^2) = \sigma^2 + \mu^2$. Por otro lado los momentos muestrales se definen como $m_1 = \frac{1}{n} \sum_{i=1}^n X_i$ y $m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$.

Tomando en consideración la relación $m_t = \mu_t$ tendremos que : $\mu = \frac{1}{n} \sum_{i=1}^n X_i =$

$\bar{X}$ y $\sigma^2 + \mu^2 = \frac{1}{n} \sum_{i=1}^n X_i^2$, entonces

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

Entonces los estimadores por el método de los momentos son

$$\hat{\mu} = \bar{X} \quad \text{y} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

6.0.3. Estimación por intervalo.

La estimación puntual no es muy conveniente, pues con el procedimiento de estimación de un parámetro a través de un único valor no se puede determinar el error de muestreo, ni la precisión de la estimación, ni la confianza que merece tal estimación.

Hay otro método para hacer una estimación mucho más precisa, la estimación por **intervalos de confianza**. Este método consiste en el procedimiento de encontrar un intervalo de valores dentro del cual se espera que se encuentre un parámetro poblacional.

Definición 6.5. Sea $\alpha \in (0, 1)$. Un intervalo de confianza para un parámetro desconocido θ de una distribución de probabilidad es un intervalo aleatorio de la forma $(\hat{\theta}_1, \hat{\theta}_2)$, en donde $\hat{\theta}_1$ y $\hat{\theta}_2$ son estadísticas muestrales tales que:

$$P(\hat{\theta}_1 < \theta < \hat{\theta}_2) = 1 - \alpha$$

A las estadísticas $\hat{\theta}_1$ y $\hat{\theta}_2$ se les conoce como límites inferior y superior, respectivamente, del intervalo de confianza. A los números α y $1 - \alpha$ se les conoce como nivel de significación y grado o nivel de confianza, respectivamente. En general, se toma el valor de α cercano a 0 de tal forma que el grado de confianza, $1 - \alpha$, es cercano a 1. Entonces el nivel de confianza es la probabilidad de que el parámetro poblacional se encuentre dentro del intervalo encontrado. Los niveles de confianza más ampliamente usados son 0,95 y 0,99, sin embargo puede usarse cualquier probabilidad cercana a 1.

6.0.4. Interpretación de un intervalo de confianza

Según la definición anterior; podríamos realizar la interpretación de dos maneras distintas, que son:

- el verdadero valor del parámetro desconocido θ se encuentre entre los valores $\hat{\theta}_1$ y $\hat{\theta}_2$ con un grado de confiabilidad de $1 - \alpha$; o también
- la probabilidad de que el verdadero valor del parámetro desconocido θ se encuentre entre los valores $\hat{\theta}_1$ y $\hat{\theta}_2$ es igual a $1 - \alpha$.

Para entender mejor el concepto de intervalo de confianza vamos a suponer que seleccionamos 100 muestras de una población y calculamos la media de las muestras e intervalos de confianza del 95 % para cada muestra. Descubriremos que cerca de 95 de los 100 intervalos de confianza contienen la media poblacional.

6.0.5. Pasos para construir un intervalo de confianza

1. Establecer el nivel de confianza.
2. Determinar el valor de la variable aleatoria estándar.
3. Calcular los estadísticos de la muestra.
4. Calcular el error estándar.
5. Calcular el error máximo de estimación.
6. Determinar los límites del intervalo de confianza e interpretar.

6.0.5.1 Intervalos de confianza para estimar la media de una población

Para la estimación de la media μ de una población se deben tener en cuenta las siguientes condiciones:

- Tomar una muestra aleatoria de tamaño n de la población cuya media se quiere estimar.
- El estadístico a utilizar es la media muestral $\bar{X}$.
- La distribución muestral a considerar es la distribución muestral de medias.

6.0.5.2 Intervalos de confianza para estimar la media de una población con muestras grandes

Recordemos que si la muestra es lo suficientemente grande, esto es $n \geq 30$, la distribución muestral de medias por aplicación del teorema central del límite se aproxima a una distribución normal con media $\mu_{\bar{X}} = \mu$ y varianza $\sigma_{\bar{X}}^2$. Entonces la v.a.

$$Z = \frac{\bar{X} - \mu_{\bar{X}}}{\sigma_{\bar{X}}} \sim N(0, 1)$$

Por lo tanto para encontrar el intervalo de confianza podríamos establecer un nivel de confianza de $1 - \alpha$, que sería la probabilidad de que Z se encuentre entre dos valores, esto es

$$P(Z_1 < Z < Z_2) = P\left(Z_1 < \frac{\bar{X} - \mu_{\bar{X}}}{\sigma_{\bar{X}}} < Z_2\right) = 1 - \alpha$$

aquí figura

Como la distribución normal tipificada está centrada en el cero y es simétrica entonces podríamos establecer que $Z_1 = -Z_2$. Si $Z_c = Z_2$ y se despeja $\mu_{\bar{X}}$ en expresión

$$Z_1 < \frac{\bar{X} - \mu_{\bar{X}}}{\sigma_{\bar{X}}} < Z_2$$

se tendrá

$$\bar{X} - Z_c \sigma_{\bar{X}} < \mu_{\bar{X}} < \bar{X} + Z_c \sigma_{\bar{X}}$$

que generalmente se abrevia como

$$\bar{X} \pm Z_c \sigma_{\bar{X}}$$

con lo cual el intervalo buscado para la media poblacional μ es

$$(\bar{X} - Z_c \sigma_{\bar{X}}, \bar{X} + Z_c \sigma_{\bar{X}})$$

Finalmente la expresión para el intervalo de confianza en término de probabilidad está dada por la relación

$$P(\bar{X} - Z_c \sigma_{\bar{X}} < \mu < \bar{X} + Z_c \sigma_{\bar{X}}) = 1 - \alpha$$

Nota: Recordar que si la población es infinita $\sigma_{\bar{X}}^2 = \frac{\sigma^2}{n}$, de lo contrario $\sigma_{\bar{X}}^2 = \frac{\sigma^2}{n} \cdot \frac{N-n}{N-1}$, donde N es el tamaño de la población. Si se desconoce el valor de la varianza poblacional σ^2 , se ha de utilizar la varianza muestral S^2 para encontrar el intervalo.

Ejemplo 6.6. Los resultados siguientes representan las calificaciones de una muestra aleatoria de estudiantes en el primer examen de estadística elemental. Elaborar un intervalo de confianza del 95 % para estimar la media poblacional.

23	60	79	32	57	74	52	70	82	36
80	77	81	95	41	65	92	85	55	76
52	10	64	75	78	25	80	98	81	67
41	71	83	54	64	72	88	62	74	43
60	78	89	76	84	48	84	90	15	79
34	67	17	82	69	74	63	80	85	61

Desarrollo

1. El nivel de confianza ya está establecido como 95 %. Entonces $1 - \alpha = 0,95$
2. Como se trata de estimar la media poblacional y $n = 60 > 30$, la variable aleatoria estándar a utilizar es Z de la distribución normal estándar. Como $1 - \alpha$ es la probabilidad de que la media poblacional se encuentre dentro del intervalo buscado (centro de la curva), α es la probabilidad de que no se encuentre en el intervalo (extremos de la curva), y cada extremo de la curva o cola corresponde al valor $\frac{\alpha}{2}$.

Como la distribución normal estándar se tabula dos maneras: la primera utilizando la función de distribución (tabla 1) y la segunda integrando la función de densidad en el intervalo que va de cero a cualquier valor positivo de Z (tabla 2). Como nosotros utilizaremos la tabla 2, busquemos en dicha tabla el valor de Z que corresponde al área de $0,5 - \frac{\alpha}{2}$, que resulta ser 1,96.

3. Para estimar la media poblacional necesitamos calcular los estadísticos de la muestra que son la media y la varianza muestral. Entonces la media muestral será

$$\bar{X} = \frac{1}{60} \sum_{i=1}^{60} X_i = \frac{3929}{60} = 65,483$$

En el caso de la varianza muestral se puede optar por S^2 ó $\hat{S}^2$, la elección es del investigador, pero generalmente se prefiere usar $\hat{S}^2$ ya que es un estimador insesgado de la varianza poblacional σ^2 . Para fines comparativos calculemos los dos

$$S^2 = \frac{1}{60} \sum_{i=1}^{60} X_i^2 - \bar{X}^2 = \frac{283635}{60} - \left(\frac{3929}{60}\right)^2 = 439,183$$

y

$$\hat{S}^2 = \frac{60}{60-1} S^2 = 446,627$$

4. Como no conocemos el tamaño de la población se asume que es infinita. Calculemos ahora el error estándar utilizando la desviación estándar muestral para las dos situaciones (S y $\hat{S}$), esto se hace debido a que no conocemos el valor de σ^2 . Por lo tanto

$$\sigma_{\bar{X}} = \frac{S}{\sqrt{60}} = 2,705 \quad \text{y} \quad \sigma_{\bar{X}} = \frac{\hat{S}}{\sqrt{60}} = 2,728$$

5. A continuación se calcula el error máximo de estimación denotado por E para las dos situaciones, entonces

$$E = Z_c \sigma_{\bar{X}} = (1,96)(2,705) = 5,302$$

y

$$E = Z_c \sigma_{\bar{X}} = (1,96)(2,728) = 5,347$$

6. Finalmente se calculan los límites del intervalo de confianza de la siguiente manera:

- Restando a la media de la muestra el error máximo de estimación se obtiene el límite inferior.
- Sumando a la media de la muestra el error máximo de estimación se obtiene el límite superior.

Entonces si utilizamos S como estimación de σ , los límites inferior y superior serán respectivamente

$$\bar{X} - E = 60,181 \quad \text{y} \quad \bar{X} + E = 70,785$$

por lo que el intervalo de confianza buscado será (60,181 ; 70,785), es decir

$$P(60,181 < \mu < 70,785) = 0,95$$

Este resultado se interpreta de la siguiente manera: “La calificación media de los estudiantes en el primer examen de estadística elemental, se encuentre entre 60,181 y 70,785” con un grado de confianza del 95 %.

Si por el contrario utilizamos $\hat{S}$, los límites inferior y superior serán respectivamente

$$\bar{X} - E = 60,136 \quad \text{y} \quad \bar{X} + E = 70,83$$

por lo que el intervalo de confianza buscado será (60,136 ; 70,83), es decir

$$P(60,136 < \mu < 70,83) = 0,95$$

Este resultado se interpreta de la siguiente manera: “Hay una probabilidad de 0,95 de que la calificación media de los estudiantes en el primer examen de estadística elemental, se encuentre entre 60,136 y 70,83”.

Si comparamos los intervalos obtenidos vemos que hay muy poca diferencia, pero la obtenida con $\hat{S}$ es un poco más ancha y por lo tanto un poco más fiable.

6.0.6. Intervalos de confianza para μ media cuando se muestrea una distribución normal con varianza conocida.

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución normal con media desconocida μ , pero con varianza σ conocida. El interés recae en la construcción de un intervalo de confianza de un $100(1 - \alpha) \%$ sobre μ y en donde α es un número pequeño tal que $0 < \alpha < 1$. La construcción de un intervalo de confianza se hace con base en el mejor estimador de μ , explícitamente la media muestral $\bar{X}$.

Cuando se estima la media poblacional a través de la media muestral y cuando la desviación estándar de la población es conocida, el máximo error de estimación dado para un nivel de confianza $1 - \alpha$ está dado por la siguiente ecuación.

$$E = z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

siendo $z_{\alpha/2}$, el cuantil de la distribución normal estándar que arrastra una probabilidad de $\alpha/2$, con α nivel de significancia establecido, por ejemplo si se desea tener un nivel de confianza del 90 %, entonces α va a ser del 0,1 y $\alpha/2$ va a ser 0,05 el calculo de los valores para que z se tiene una probabilidad del 10 %. Para el calculo de los intervalos se utiliza la expresión siguiente

$$\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

6.0.7. Intervalos de confianza para μ media cuando se muestrea una distribución normal con varianza desconocida.

Recuerdese que cuando se muestrea una distribución normal $N(\mu, \sigma)$ para lo cual no se conoce acerca de μ y σ , la variable aleatoria

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

tiene una distribución t de Student con $n - 1$ grados de libertad. Por lo tanto, es posible determinar el valor cuantil de T . El procedimiento es similar a cuando se conoce σ^2 , solo se reemplaza σ por S y la distribución normal estándar Z , por la distribución T de Student.

$$\bar{x} - t_{\alpha/2} \frac{S}{\sqrt{n}} < \mu < \bar{x} + t_{\alpha/2} \frac{S}{\sqrt{n}}$$

6.0.8. Intervalos de confianza para la diferencia de medias cuando se muestrean dos distribuciones normales independientes.

Sean $X_1, X_2, \dots, X_{n_x}$ y $Y_1, Y_2, \dots, Y_{n_y}$ dos muestras aleatorias de dos distribuciones normales independientes, con medias μ_x y μ_y y varianzas σ_x^2 y σ_y^2 . Se desea construir un intervalo para la diferencia $\mu_x - \mu_y$.

$$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_x - \mu_y)}{\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}}$$

es $N(0, 1)$. De esta forma es posible encontrar el valor cuartil

$$\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}} < (\bar{X} - \bar{Y}) < \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}$$

Igual que en los casos anteriores de muestreo de varianza conocida y no conocida en estos casos también en vez de usar la distribución Z para el caso conocido usamos la distribución T .

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_x - \mu_y)}{\sqrt{\frac{S_x^2}{n_x} + \frac{S_y^2}{n_y}}}$$

tiene una distribución t de Student con $k = n_x + n_y - 2$ grados de libertad.

Ejemplo 6.7 (Ejercicio de ejemplo sobre diferencia de medias.).

Ejemplo 6.8 (Solución del ejemplo sobre diferencia de medias.).

Ejercicio 6.1 (Ejercicios sobre diferencia de medias.). *dado*

6.0.9. Intervalos de confianza para σ^2 varianza cuando se muestrea una distribución normal con media desconocida.

Para encontrar un intervalo de confianza con un cierto grado de fiabilidad $1 - \alpha$, para todo $0 < \alpha < 1$, que contenga a la varianza poblacional σ^2 , si esta se desconoce, se puede utilizar a la v. a. $\frac{nS^2}{\sigma^2}$, donde n es el tamaño de muestra y S^2 es la varianza muestral. Teniendo en cuenta que esta v. a. se distribuye como una ji-cuadrada con $n - 1$ grados de libertad, puede seleccionarse dos valores de esta distribución (χ_c^2 y χ_l^2), tales que la probabilidad de que $\frac{nS^2}{\sigma^2}$ esté entre estos

dos valores sea igual al grado de fiabilidad propuesto, tal como lo muestra la figura 9.1. Esto es

$$P\left(\chi_c^2 < \frac{nS^2}{\sigma^2} < \chi_l^2\right) = 1 - \alpha$$

Tomando la expresión $\chi_c^2 < \frac{nS^2}{\sigma^2} < \chi_l^2$ y despejando en ella a σ^2 , se tendrá

$$\frac{\chi_c^2}{nS^2} < \frac{1}{\sigma^2} < \frac{\chi_l^2}{nS^2} \longrightarrow \frac{nS^2}{\chi_l^2} < \sigma^2 < \frac{nS^2}{\chi_c^2}$$

Entonces la probabilidad de que la varianza poblacional esté entre los valores $\frac{nS^2}{\chi_l^2}$ y $\frac{nS^2}{\chi_c^2}$ estará dada por la relación

$$P\left(\frac{nS^2}{\chi_l^2} < \sigma^2 < \frac{nS^2}{\chi_c^2}\right) = 1 - \alpha$$

con lo cual el intervalo de confianza de σ^2 con un nivel de confianza de $1 - \alpha$ estará dada por

$$\left(\frac{nS^2}{\chi_l^2} ; \frac{nS^2}{\chi_c^2}\right)$$

Analizando la elaboración de la tabla de la distribución ji-cuadrada encontramos que si $X \sim \chi^2(n)$ entonces $P(X \leq x) = p$, donde p es el área bajo la curva y va desde el valor cero a un cierto valor $x = \chi_{[p; \nu]}^2$, donde ν son los grados de libertad, tal como lo muestra la siguiente figura

6.0.10. Intervalos de confianza para el cociente de dos varianzas cuando se muestrean dos distribuciones normales independientes.

Sean dos muestras aleatorias provenientes de dos distribuciones normales con medias y varianzas desconocidas. Y sean n_x y n_y el tamaño de muestras y S_x^2 y S_y^2 las varianzas muestrales. El interés se centra en construir un intervalo de confianza para el cociente σ_y^2/σ_x^2 de las dos varianzas poblacionales. Recordando que la variable aleatoria $(S_x^2/\sigma_x^2)/(S_y^2/\sigma_y^2)$ tiene una distribución F con $n_x - 1$ y $n_y - 1$ grados de libertad. Entonces

$$P\left(a < \frac{S_x^2/\sigma_x^2}{S_y^2/\sigma_y^2} < b\right) = 1 - \alpha$$

donde a y b son los valores de los cuantiles inferior y superior de una distribución F tales que

$a = 1/f_{1-\alpha/2, n_y-1, n_x-1}$ y $b = 1/f_{1-\alpha/2, n_x-1, n_y-1}$
de esta manera un intervalo para σ_y^2/σ_x^2 está dado por

$$(aS_Y^2/S_X^2 ; bS_Y^2/S_X^2)$$

6.0.11. Intervalos de confianza para el parámetro de proporción p cuando se muestrea con distribución binomial.

Cuando el interés del estudio tiene una variable aleatoria binomial, suponiendo una probabilidad constante e independiente, si la muestra aleatoria de tamaño n y el parámetro p que representa la proporción de interés es desconocido, se podrá hallar un intervalo de confianza para p . A pesar de poder determinar intervalos exactos para p , se optará por el intervalo basado en grandes muestras. La razón es que gracias al teorema central del límite cuando n tiende a infinito la distribución binomial tiende hacia la normal.

Recordar que para n grande, la variable aleatoria $(X - np)/\sqrt{np(1-p)}$ es aproximadamente $N(0; 1)$ Entonces puede demostrarse que

$$\frac{\hat{P} - P}{\sqrt{\frac{\hat{P}(1-\hat{P})}{n}}}$$

también tiende a $N(0; 1)$ para n grande.

Entonces el intervalo de confianza para el parámetro de proporción p es

$$\left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-p)}{n}} ; \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-p)}{n}} \right]$$

donde el estimador de máxima verosimilitud $\hat{p} = x/n$ se obtiene de la muestra aleatoria de tamaño n .

Referencias

Canavos, George C. 1995. *Probabilidad Y Estadística. Aplicaciones y métodos*. –México: McGraw-Hill. Traducción de: Edmundo Gerardo Urbina Medal Revisado por: Gustavo Javier Valencia Ramírez.: – 651 p.

Triola, M. F. 2004. *Estadística*. 9no edn. México: Pearson Educación.

Walpole, R. 2012. *Probabilidad y estadística para ingeniería y ciencias*. 9na edn.
México: Pearson Educación.